


* CNN (Convolution Neural Network) \rightarrow Conv $\xrightarrow{[l]}$ layer에서
 * Pooling (풀링층)

filter는?
 $f^{[l]}$: filter size.
 filter의 채널수는 동일
 $= n_c^{[l-1]}$
 input 이미지
 $n_w^{[l-1]} \times n_h^{[l-1]} \times n_c^{[l-1]}$
 이진층의 채널수

* filter의 갯수는 $[l]$ 층이 같아서
 유지됨. (2개라 가정).




parameter는? $[l-1]$ 층
 $\Rightarrow (f^{[l-1]} \times f^{[l-1]} \times n_c^{[l-1]} + 1) \times (\text{filter의 갯수})$

$[l]$ 층
 $= (f^{[l]} \times f^{[l]} \times n_c^{[l-1]} + 1) \times (\text{filter 갯수})$

parameter수는 신경망층이
 깊어질수록 증가.
 이미지의 크기는 감소

* Pooling층 기능: 표현의 크기를 줄임으로써 계산속도를 높임.
 -> 특징 검출이 됨.

* Max pooling



filter 2x2를 사용하고
 stride=2로 하는 결과와 동일
 $\lfloor \frac{4-2}{2} + 1 \rfloor = 2$

Max pooling을 통해 각 칸의 최대
 크기만큼 뽑아냄.

max pooling의 $\left\{ \begin{array}{l} f=2 \\ s=1 \end{array} \right.$

Max pooling 아냐


하이퍼파라미터

1 2 2

패스나

Max pooling은
* f 와 S 는 쌍수(고정값)이라서
Gradient Descent 등의 학습을 시키기 어렵다.

pooling은 각 범위에서의 최대
값이 그 범위에서 가장 feature를
잘 나타내는 특성일 거.




Max pooling

$$f=3$$

$$S=1$$

$$\left\lfloor \frac{5-3}{1} + 1 \right\rfloor = 3$$




3×3

(5×5 input에서 3×3 칸씩 잡아서 가장 큰 수를
뽑고 칸칸씩 이동)

2차원 Max pooling

3차원도 동일



$5 \times 5 \times N_c$

max pooling



$3 \times 3 \times N_c$

pooling 특징

input과 output의
 N_c (채널수가 같다)

채널의 수가 같다.

max pooling은 각 채널별로 적용

* Average pooling은 각 filter칸의 평균을 output에 저장

* Summary of pooling \Rightarrow 하이퍼파라미터들

f : filter size

S : stride

출력

계산식은 conv와 동일

$$\left\lfloor \frac{n+2p-f}{S} + 1 \right\rfloor$$

Max or average pooling

또한 pooling의 in/out img의 N_c 는 동일 ..

때때로 Max pooling에서는 padding을 사용하지 않는다.

$\therefore p=0$

$$n_H \times n_W \times n_C \xrightarrow{\text{pooling}} \left\lfloor \frac{n_H - f}{s} + 1 \right\rfloor \times \left\lfloor \frac{n_W - f}{s} + 1 \right\rfloor \times n_C$$

→ 풀림의 의미한점은 학습하는 변수가 없다.


→ 풀림(가능) No parameters to learn.
 ↳ because f, s 가 고정변수인 Hyper parameters 이기 때문

* Max pooling 특징은

이미지 특징이 필터 한 부분에서 겹칠이 되면 최댓값을 남기고,

그렇지 않으면 다른 최대값이 바뀔 때 상대적으로 작아져서 특징을 더 잘 남긴다.

* CNN Example (아래 Conv와 Pooling층까지 이해).




= Layer 1 (신경망에서)

일반적인 신경망층을 셀 때는 W와 편향을 가지는 층만 계산

pool층은 W가 없고 Hyper-parameters 가 아니므로 (Conv1, Pool)을 Layer 1으로 본다.



$f=5$
 $s=1$
 $p=0$
 $\text{filter size}=16$
 $\lfloor \frac{14-5}{1} + 1 \rfloor = 10$



→ 예) 5x5x16=400이 POOL 2를 한 줄로 펼쳐서

Layer 2 = 1
 5x5x16 =
400



400x1의 벡터로 만든다
(여러개 뉴런처럼)

이 400개 뉴런으로 12개 뉴런을 가진 층을 만든다

400개 뉴런이 12개 뉴런과 fully connect



120


FC3

fully connected

$w^{(3)}$ (120, 400)의 크기를 가지고 완전연결

400개 뉴런이 각각 12개 뉴런과 연결되어 있다.

$b^{(3)} = (120)$



h2는 84개로 fully connect

1. 여러 뉴런이 사용된다.
→ Softmax가 보이기
적용 가능한 84개의 열벡터가 생성

이러한 숫자를 0~9 중이 갖기 때문이다

layer more deep



n_H, n_w decrease ↓

$n_c \propto \text{increase } \gamma$

일반적 CNN (신경망) 구조 : $\text{CONV} \rightarrow \text{POOL} \rightarrow \text{CONV} \rightarrow \text{POOL} \rightarrow \text{FC}$
 $\text{Softmax} \leftarrow \text{FC} \leftarrow \text{FC}$

detail :	Activation shape	Activ size	parameter 개수
input	$(32, 32, 3)$	$a^{(0)} \quad 32 \times 32 \times 3 = 3072$	0
CONV1 ($f=5, s=1$)	$(28, 28, 8)$	$a^{(1)} \quad 6272$	$208 (5 \times 5 \times 3 + 1 \times 8)$
POOL1	$(14, 14, 8)$	$a^{(2)} \quad 1568$	0
CONV2 ($f=5, s=1$)	$(10, 10, 16)$	$a^{(3)} \quad 1600$	$400 = (5 \times 5 \times 8 + 1 \times 16)$
POOL2	$(5, 5, 16)$	400	0
FC3	$(120, 1)$	120	$120 \times 400 + 1 = 48001$
FC4	$(84, 1)$	84	$84 \times 120 + 1 = 10081$
Softmax	$(10, 1)$ 0~9 : 10개 범위의 클래스	10	$84 \times 10 + 1 = 841$


* POOL층은 parameter가 따로 없다 (f, s 등의 8비트 parameter는 존재)
 CONV층의 parameter들은 FC층에 존재
 활성화 size도 항상 줄어들수록 감소.

신경망 : (CONV, POOL, FC) 후에 softmax.

fully-Connected층으로 갈 때



$n_h \times n_w \times n_c$ 의 act size를 환원시켜서



$[n_h n_w n_c, 1]$ 의

벡터로 만들기


W역시 행렬

c) $(400, 1)$ 에서 $W(120, 400)$

$\downarrow F(3)$

$(120, 1)$ 로 줄이2

\rightarrow
 $W(84, 120)$



마지막 수정: 오후 7:25